

Learning Lab M2DFS — MCP (Model Context Protocol)

Étude d'adoption — copilote conseiller de Velora (e-commerce fictif)

Rendu écrit : rapport + POC (dépôt GitHub)

POC : serveur MCP (TypeScript) + agent compatible OpenAI (cloud ou local)

1. Note de cadrage stratégique

1.1 Contexte et entreprise

Velora est un pure-player e-commerce de mode et lifestyle (entreprise fictive support de cette étude) : ~110 salariés, ~35 M€ de CA, un catalogue d'environ **12 000 références** et une équipe de ~**15 conseillers** au service client (chat + e-mail).

Problème observé. Pour répondre à un client, un conseiller doit aujourd'hui jongler entre plusieurs outils : back-office (stock, commandes), fiches produit, documents de politique (retours, livraison). Conséquences : temps de réponse élevé, réponses parfois incohérentes d'un conseiller à l'autre, et **onboarding long** des nouvelles recrues.

Besoin métier. Un **copilote conseiller** : un assistant IA capable de répondre en langage naturel en s'appuyant **uniquement** sur les données internes (catalogue, stock, commandes, politiques), de façon **fiable et sourcée**, pour réduire le temps de réponse et homogénéiser la qualité.

1.2 La technologie étudiée : MCP (Model Context Protocol)

MCP est un **standard ouvert** qui normalise la façon dont un modèle de langage se connecte à des **outils** et des **données** externes. Image courante : le « **port USB-C des applications d'IA** » — au lieu d'écrire une intégration sur-mesure par modèle, on expose ses capacités **une seule fois** via un **serveur MCP**, que n'importe quel client compatible peut consommer.

- **Origine & gouvernance** : introduit par Anthropic (fin 2024), il est désormais **gouverné de façon neutre** par l'*Agentic AI Foundation* (sous l'égide de la Linux Foundation, depuis décembre 2025).
- **Primitives** (3) : **Tools** (actions appelables), **Resources** (données en lecture), **Prompts** (gabarits réutilisables).
- **Transport** : `stdio` (serveur local) ou *Streamable HTTP* (serveur distant). Protocole **JSON-RPC**, révision **2025-11-25**.

1.3 Argumentaire décisionnel — gains attendus

Axe	Gain apporté par MCP
Maintenabilité	Outils centralisés dans un serveur, schémas typés (Zod / JSON Schema). Une seule source de vérité, testable isolément.
Réutilisabilité	Un serveur, <i>plusieurs</i> clients : Claude Desktop, agent custom, IDE, futur agent vocal... sans réécriture.
Découplage / pas de lock-in	Le serveur est indépendant du modèle. On change de LLM (cloud ↔ local) sans toucher à l'intégration — démontré dans notre POC (bascule via <code>.env</code>).
Sécurité / gouvernance	Annotations d'outils (<code>readOnly</code> , <code>destructive</code>), périmètre d'accès maîtrisé, journalisation centralisable, <i>allow-list</i> via registre.
Scalabilité (organisationnelle)	Chaque équipe publie ses serveurs ; l'écosystème se compose au lieu de se dupliquer.
Time-to-market	SDK officiels (TS/Python), <i>MCP Inspector</i> , nombreux serveurs prêts à l'emploi.

1.4 Analyse comparative de l'écosystème

Maturité & communauté (chiffres, 2026).

- Gouvernance neutre (Linux Foundation / Agentic AI Foundation).
- **Registre officiel** de serveurs MCP : ~**9 600** serveurs, ~29 000 versions.
- ~**15 900** dépôts GitHub avec le topic `mcp-server` ; dépôt de référence `modelcontextprotocol/servers` ~**86 k** étoiles.
- ~**97 M** de téléchargements/mois des SDK (Python + TypeScript).
- **Adoption transverse** : Anthropic, **OpenAI**, Google, Microsoft, AWS, Cloudflare, GitHub... ~**41** % des organisations interrogées déclarent un usage en production (rapport Stacklok 2026).

Lecture critique : MCP n'est plus une curiosité de 2024 mais un standard **multi-éditeurs** en adoption rapide — ce qui réduit le risque de pari technologique. Sa jeunesse (spec qui évolue vite) reste à surveiller.

Comparaison des approches d'outillage d'un LLM.

Approche	Avantages	Inconvénients
Function calling « maison » (format propre à chaque API)	Démarrage immédiat, zéro dépendance	Couplé au fournisseur, non réutilisable , à re-maintenir à chaque LLM
Framework d'orchestration (LangChain, LlamaIndex)	Riche, nombreux connecteurs	Abstractions lourdes, lock-in framework , montée en version coûteuse
MCP (notre choix)	Standard ouvert , réutilisable, découplé du modèle , outillage (Inspector, registre)	Jeune (spec mouvante), sécurité à durcir (cf. menaces)

1.5 Matrice SWOT

Forces	Faiblesses
Standard ouvert, gouvernance neutre	Spécification jeune, encore en évolution rapide
Découplage modèle/données (pas de lock-in)	Outillage de debug/observabilité encore vert
Réutilisable par plusieurs clients	Courbe d'apprentissage côté développeurs
SDK officiels + Inspector + large écosystème	Qualité du <i>tool calling</i> variable selon les modèles (surtout locaux)

Opportunités	Menaces
Écosystème de serveurs réutilisables (registre)	Sécurité : injection de prompt, <i>tool poisoning</i>
Vers des agents multi-outils plus autonomes	<i>Confused deputy</i> / gestion des jetons OAuth
Standard adopté par les principaux éditeurs	Agents sur-privilégiés → surface d'attaque élargie
Mutualisation entre équipes internes	Dépendance à la trajectoire de la spec (versions)

Mitigations retenues pour le POC : outils en lecture seule par défaut (annotation `readOnlyHint`), unique action d'écriture restreinte (retour possible uniquement sur commande livrée) avec mention *human-in-the-loop*, *system prompt* anti-invention, schémas d'entrée plats et validés (Zod), journaux sur `stderr`.

1.6 Décision


Le POC (bloc 2) démontre la **viabilité technique** et la **valeur** de MCP pour le copilote conseiller de Velora. **Recommandation : adoption**, sous conditions de durcissement sécurité (revue des actions d'écriture, *allow-list* de serveurs, journalisation) et de choix de modèle (cf. budget, bloc 3).

2. Démarche R&D et preuve de concept

2.1 Objectif du POC

Démontrer, sur le cas Velora, qu'un **serveur MCP** peut exposer les données métier (catalogue, stock, commandes, politiques) et qu'un **agent IA** les exploite pour répondre à un conseiller — le tout **testable sans clé payante**.

2.2 Architecture



Deux briques **découplées** :

1. **Serveur MCP** (`src/server.ts`) — indépendant de tout LLM. Expose outils, ressources et un prompt ; lit les données via Prisma/SQLite.
2. **Agent** (`src/agent/`) — un **hôte MCP** qui : se connecte au serveur, convertit les outils MCP en *functions* OpenAI (`bridge.ts`), puis exécute une **boucle *tool-use*** contre un endpoint **compatible OpenAI**.

2.3 Choix techniques

Élément	Choix	Justification
Langage	TypeScript (Node 20+)	Cohérent avec la stack full-stack JS de Velora
Serveur MCP	<code>@modelcontextprotocol/sdk</code> (<code>McpServer</code>)	SDK officiel, API haut niveau, transport stdio
Validation	Zod	Schémas d'entrée typés + descriptions exposées au LLM
Données	Prisma 7 + SQLite (adapter better-sqlite3)	Réaliste, zéro serveur à installer, <i>seed</i> reproductible
Agent	SDK <code>openai</code> avec <code>baseUrl</code> configurable	Compatible OpenAI, Ollama, LM Studio... via <code>.env</code>
Tests	Vitest	Intégration outils (sans LLM) + boucle agent (LLM simulé)

2.4 Portabilité & test sans clé payante (note importante)

L'agent utilise l'**API compatible OpenAI**. Il fonctionne donc avec : **OpenAI** (clé payante), **un modèle local** (Ollama / LM Studio → **gratuit, sans clé**), ou tout fournisseur compatible (Groq, Together, OpenRouter...). On change de fournisseur en modifiant **uniquement** `LLM_BASE_URL` , `LLM_API_KEY` , `LLM_MODEL` dans `.env` .

Le **serveur MCP est indépendant du LLM** : il se teste **seul**, sans aucune clé, via `npm test` ou le *MCP Inspector*. Il est aussi consommable par **Claude Desktop** (configuration fournie) — illustration concrète du « un serveur, plusieurs clients ».

Cette note figure aussi dans le `README.md` et le fichier `.env.example` .

2.5 Outils et ressources exposés

Outils (6) — voir résultats réels dans `../demo/outils-demo.md` : `search_products` , `get_product` , `check_stock` , `get_order_status` , `get_return_policy` , `create_return_request` .

Ressources (2) : `policy://returns` , `policy://shipping` (Markdown). **Prompt** (1) : `conseiller_reply` (gabarit de réponse conseiller).

2.6 Dépôt et installation

Dépôt : `https://github.com/Onitsag/velora-mcp-copilote` . Guide complet d'installation **sans friction** dans le `README.md` . En résumé :

```
npm install
cp .env.example .env      # profil local Ollama par défaut
npm run db:setup           # crée la base SQLite + données fictives
npm run build
npm test                   # 12 tests, sans clé API
```

2.7 Cas d'usage testés en conditions réelles

Le fichier `../demo/outils-demo.md` (généré par `npm run showcase`) contient des **appels réels** et leurs **résultats bruts**, dont des cas limites probants :

- recherche filtrée (robes en stock), fiche produit avec **stock par taille** ;
- statut d'une commande connue (`VEL-1003` → *En préparation*, articles + total) ;
- **garde-fou** : `create_return_request` **refuse** une commande non livrée (`VEL-1003`) et **accepte** une commande livrée (`VEL-1001`).

Côté agent, `npm run demo` (avec un LLM configuré) produit des transcrits dans `docs/demo/transcripts/` . La **boucle tool-use** est par ailleurs validée **sans clé** par `tests/agent.test.ts` (LLM déterministe simulé) : l'agent appelle réellement `get_order_status` puis fonde sa réponse sur le résultat.

2.8 Tests & qualité

`npm test` exécute **12 tests** (3 fichiers) :

- `tests/tools.test.ts` — intégration des 6 outils via un **vrai client MCP** (sous-processus serveur), incluant les cas d'erreur et le garde-fou de retour ;
- `tests/bridge.test.ts` — normalisation des résultats MCP → texte ;
- `tests/agent.test.ts` — boucle *tool-use* de l'agent avec LLM simulé.

`pretest` régénère la base et compile, garantissant des tests **déterministes**.

2.9 Sécurité (mesures du POC)

- Outils **en lecture seule** par défaut (`readOnlyHint`) ; seule écriture : `create_return_request` , **restreinte aux commandes livrées**, avec mention explicite *human-in-the-loop*.
- *System prompt* **anti-invention** (le modèle doit s'appuyer sur les outils).
- **Schémas d'entrée plats et validés** (Zod) → compat large + moindre surface.
- Logs serveur sur **stderr** uniquement (stdout réservé au protocole).

2.10 Limites assumées du POC

Données **fictives** ; recherche **lexicale simple** (pas de recherche vectorielle) ; pas d'authentification ni de multi-tenant ; transport **stdio** local (pas d'exposition HTTP distante). Ces points sont des pistes d'industrialisation, hors périmètre d'un POC.

3. Étude budgétaire et d'adoption

Tarifs éditeurs exprimés en USD ; parité ~1:1 € retenue pour simplifier la lecture. Volumes = hypothèses de travail pour Velora (~15 conseillers).

3.1 Hypothèse de volume

Paramètre	Hypothèse
Conseillers	15
Requêtes copilote / conseiller / jour	~30
Jours ouverts / mois	~21
Total requêtes / mois	~10 000
Tokens / requête (avec aller-retours d'outils)	~3 000 entrée + ~500 sortie
Volume mensuel	~30 M tokens entrée + ~5 M sortie

3.2 Coûts directs

a) Inférence LLM (cœur du coût variable)

Option	Prix (entrée / sortie, /M)	Coût mensuel estimé*
OpenAI gpt-4o-mini	0,15 / 0,60	~7,5 €
Claude Haiku 4.5	1,00 / 5,00	~55 €
OpenAI gpt-4o	2,50 / 10,00	~125 €
Modèle local (Ollama/LM Studio)	0 / token	0 € (coût = matériel/ops)

* 30 M × prix entrée + 5 M × prix sortie.

Leviers d'optimisation : *prompt caching* (−90 % sur l'entrée mise en cache — le *system prompt* et les définitions d'outils sont réutilisés à chaque requête) et *Batch API* (−50 %) pour les traitements asynchrones. Avec *caching*, le coût gpt-4o-mini devient **négligeable** (quelques euros/mois).

b) Hébergement & licences

- **Serveur MCP** : petit conteneur (1 vCPU / 1 Go) ≈ **5–15 €/mois**, ou mutualisé avec l'infra existante ≈ négligeable.

- **Base de données** : Velora dispose déjà de sa base produit/commandes.
- **Licence MCP : 0 €** (standard open source).
- **Option auto-hébergée** : machine avec GPU 16 Go (~1 500–2 500 € *one-shot*) pour servir un modèle 8B, ou serveur d'inférence mutualisé.

3.3 Coûts indirects

Poste	Estimation
Industrialisation POC → prod (auth, connecteurs réels, transport HTTP, observabilité, revue sécu, intégration UI)	~15–25 j/h
Formation des conseillers (outil conversationnel simple)	~0,5 j × 15 ≈ 7,5 j/h
Montée en compétence MCP des développeurs	~2–3 j/h
Maintenance courante	~1–2 j/mois

3.4 Analyse d'impact

- **Courbe d'apprentissage** : **faible** côté conseillers (c'est un chat) ; **modérée** côté développeurs (MCP récent, mais SDK + Inspector matures).
- **Productivité** : gain attendu sur le **temps de recherche d'information** (objectif –30 à –50 % sur ces tâches), **onboarding raccourci** des nouveaux conseillers (le copilote sert de mémoire opérationnelle).
- **Risque transitoire** : fiabilité (hallucinations) au démarrage → atténué par les garde-fous (anti-invention, lecture seule par défaut, supervision initiale).

3.5 Synthèse ROI

À ces volumes, le **coût d'inférence cloud est marginal** (≈ 7,5 €/mois en gpt-4o-mini, voire ~0 € en local) face au **temps conseiller économisé** (le coût dominant est salarial). L'investissement réel est l'**industrialisation** (~15–25 j/h) et la **conduite du changement**. Le découplage MCP permet en outre de **commencer en local (0 €, données sur site)** puis de basculer vers une API managée si besoin — **sans réécrire** le serveur. Décision : **adoption recommandée**, démarrage en local pour la confidentialité et le coût.

4. Ingénierie pédagogique

L'objectif du Learning Lab est aussi de **transmettre** la compétence. Cette section décrit l'atelier conçu pour des pairs développeurs. Le matériel complet est dans `../atelier/`.

4.1 Objectifs pédagogiques

À l'issue de l'atelier (≈ 1 h 30), un participant sait :

- 1. **Expliquer** ce qu'est MCP et ses 3 primitives (tools, ressources, prompts) ;
- 2. **Lire** un serveur MCP existant et le tester avec le *MCP Inspector* ;
- 3. **Écrire un nouvel outil** (schéma Zod + handler) et le faire apparaître ;
- 4. **Comprendre le pont** MCP → agent compatible OpenAI (réutilisation des outils) ;
- 5. **Tester** son outil (Vitest) sans dépendre d'un LLM.

4.2 Scénario / déroulé chronologique

Durée	Phase	Contenu
20 min	Théorie	Pourquoi MCP ? Le problème Velora ; primitives ; « un serveur, plusieurs clients » ; sécurité (injection, <i>tool poisoning</i>).
15 min	Démonstration	Lancer le serveur + Inspector ; appeler <code>search_products</code> , <code>get_order_status</code> ; lancer l'agent (modèle local) sur une question réelle.
45 min	Coding Kata	Chaque participant ajoute l'outil <code>get_shipping_estimate</code> (cf. <code>atelier/kata.md</code>), le teste à l'Inspector puis via le test fourni.
10 min	Débrief & futur	Revue des solutions ; limites & pistes (HTTP distant, RAG, sécurité) ; projection : agents multi-serveurs.

Détail complet et minutage : `../atelier/scenario.md`.

4.3 Support d'exercice pratique (Coding Kata)

Énoncé : « Ajouter au serveur l'outil `get_shipping_estimate({ country, weightKg })` qui renvoie le délai et le tarif estimés selon la politique de livraison. » Le kata fournit un **squelette à compléter** et un **test rouge** qui doit passer au vert.

- Énoncé + étapes guidées + solution : `../atelier/kata.md`
- Squelette de départ : `../atelier/kata-starter/`

L'exercice est volontairement **isomorphe** aux outils existants : le participant réutilise le patron `registerXxx(server)` déjà en place, ce qui ancre la compétence « écrire un outil MCP » de façon

autonome.

5. Posture de Lead Developer (démarche & synthèse)

5.1 Démarche de veille

La veille a combiné sources **primaires** (spécification MCP, documentation des SDK officiels, pages de tarification éditeurs) et **secondaires** (registre officiel, retours d'adoption, littérature sécurité). Les chiffres et faits techniques du rapport ont été **vérifiés à la source** (juin 2026) plutôt que repris de mémoire — la technologie évoluant vite.

5.2 Esprit critique

MCP a été évalué **sans complaisance** : au-delà de la « hype », le rapport identifie des **faiblesses** (spec jeune, *tool calling* inégal selon les modèles) et des **menaces** réelles (injection de prompt, *tool poisoning*, sur-privileges). Le choix d'architecture **découplée** (serveur indépendant du LLM) est lui-même une réponse critique au risque de *lock-in*.

5.3 Décisions d'ingénierie notables

- **Agent compatible OpenAI** plutôt que lié à un seul fournisseur → le projet est **testable gratuitement** (modèle local) et **portable** (cloud ou local via `.env`). Décision motivée par la contrainte « le correcteur doit pouvoir tester sans clé payante ».
- **Prisma 7 + adapter** : prise en compte des évolutions récentes (driver adapters, `prisma.config.ts`) constatées **pendant** le build, et adaptation en conséquence.
- **Testabilité** : l'agent accepte un LLM **injecté**, ce qui permet de valider la boucle *tool-use* **sans clé** (test déterministe).

5.4 Vulgarisation

Le rapport s'adresse à une **direction technique** : analogies (« USB-C de l'IA »), tableaux de synthèse, SWOT, exemple budgétaire chiffré, et un POC **exécutable** documenté pas à pas. L'objectif est qu'un décideur comme un développeur puissent se forger une opinion **et** reproduire la démonstration.

5.5 Bilan

Le Learning Lab a permis de passer de la **veille** (comprendre MCP et son écosystème) à la **preuve** (un POC fonctionnel, testé, documenté) puis au **transfert** (un atelier et un kata prêts à l'emploi). La recommandation d'adoption est **étayée** par des faits, un code opérationnel et une analyse économique — tout en restant lucide sur les conditions de mise en production.