

LEARNING LAB · M2 DÉVELOPPEUR FULLSTACK

MCP : Model Context Protocol

Étude d'adoption : un copilote conseiller pour Velora (e-commerce fictif)

Auteur : Timéo GASTINEAU

Dépôt GitHub du POC :

<https://github.com/Onitsag/velora-mcp-copilote>

POC : un serveur MCP (TypeScript) et un agent compatible OpenAI, testables sans clé payante (modèle local Ollama ou serveur seul).

Sommaire

1. Note de cadrage stratégique

- 1.1 Contexte et entreprise
- 1.2 La technologie étudiée : MCP (Model Context Protocol)
- 1.3 Argumentaire décisionnel : gains attendus
- 1.4 Analyse comparative de l'écosystème
- 1.5 Matrice SWOT
- 1.6 Décision

2. Démarche R&D et preuve de concept

- 2.1 Objectif du POC
- 2.2 Architecture
- 2.3 Comment MCP fonctionne (le protocole en pratique)
- 2.4 Les primitives exposées par le serveur Velora
- 2.5 Les 6 outils en détail
- 2.6 Du serveur MCP à l'agent : le pont et la boucle tool-use
- 2.7 Choix techniques
- 2.8 Portabilité et test sans clé payante (note importante)
- 2.9 Dépôt et installation
- 2.10 Cas d'usage testés en conditions réelles
- 2.11 Tests et qualité
- 2.12 Sécurité (mesures du POC)
- 2.13 Limites assumées du POC

3. Étude budgétaire et d'adoption

- 3.1 Hypothèse de volume
- 3.2 Coûts directs
- 3.3 Coûts indirects
- 3.4 Analyse d'impact
- 3.5 Synthèse ROI

4. Ingénierie pédagogique

- 4.1 Objectifs pédagogiques
- 4.2 Scénario / déroulé chronologique
- 4.3 Support d'exercice pratique (Coding Kata)
- 4.4 Plan de transfert à l'équipe (au-delà de l'atelier)

5. Posture de Lead Developer (démarche & synthèse)

- 5.1 Démarche de veille
- 5.2 Esprit critique
- 5.3 Décisions d'ingénierie notables

5.4 Vulgarisation

5.5 Bilan

Annexe A : Installation et utilisation

Prérequis

Installation

Vérifier sans aucune clé

Lancer l'agent (copilote)

Annexe B : Preuves d'exécution (appels réels du serveur MCP)

Outils disponibles

Ressources disponibles

Rechercher les robes en stock

Fiche produit : bottines Chelsea

Vérifier le stock de la taille 39

Statut de la commande VEL-1003

Commandes du client alice.martin

Retour refusé (commande non livrée) ⚠️ (isError)

Retour accepté (commande livrée VEL-1001)

Annexe C : Ressources

1. Note de cadrage stratégique

1.1 Contexte et entreprise

Velora est un pure-player e-commerce de mode et lifestyle (entreprise fictive support de cette étude) : ~110 salariés, ~35 M€ de CA, un catalogue d'environ **12 000 références** et une équipe de ~**15 conseillers** au service client (chat + e-mail).

Problème observé. Pour répondre à un client, un conseiller doit aujourd'hui jongler entre plusieurs outils : back-office (stock, commandes), fiches produit, documents de politique (retours, livraison). Conséquences : temps de réponse élevé, réponses parfois incohérentes d'un conseiller à l'autre, et **onboarding long** des nouvelles recrues.

Besoin métier. Un **copilote conseiller** : un assistant IA capable de répondre en langage naturel en s'appuyant **uniquement** sur les données internes (catalogue, stock, commandes, politiques), de façon **fiable et sourcée**, pour réduire le temps de réponse et homogénéiser la qualité.

1.2 La technologie étudiée : MCP (Model Context Protocol)

MCP est un **standard ouvert** qui normalise la façon dont un modèle de langage se connecte à des **outils** et des **données** externes. Image courante : le « **port USB-C des applications d'IA** » : au lieu d'écrire une intégration sur-mesure par modèle, on expose ses capacités **une seule fois** via un **serveur MCP**, que n'importe quel client compatible peut consommer.

- **Origine & gouvernance** : introduit par Anthropic (fin 2024), il est désormais **gouverné de façon neutre** par l'*Agentic AI Foundation* (sous l'égide de la Linux Foundation, depuis décembre 2025).
- **Primitives** (3) : **Tools** (actions appelables), **Resources** (données en lecture), **Prompts** (gabarits réutilisables).
- **Transport** : `stdio` (serveur local) ou *Streamable HTTP* (serveur distant). Protocole **JSON-RPC**, révision **2025-11-25**.

1.3 Argumentaire décisionnel : gains attendus

Axe	Gain apporté par MCP
Maintenabilité	Outils centralisés dans un serveur, schémas typés (Zod / JSON Schema). Une seule source de vérité, testable isolément.
Réutilisabilité	Un serveur, <i>plusieurs</i> clients : Claude Desktop, agent custom, IDE, futur agent vocal... sans réécriture.
Découplage / pas de lock-in	Le serveur est indépendant du modèle. On change de LLM (cloud ↔ local) sans toucher à l'intégration, comme démontré dans notre POC (bascule via <code>.env</code>).
Sécurité / gouvernance	Annotations d'outils (<code>readOnly</code> , <code>destructive</code>), périmètre d'accès maîtrisé, journalisation centralisable, <i>allow-list</i> via registre.
Scalabilité (organisationnelle)	Chaque équipe publie ses serveurs ; l'écosystème se compose au lieu de se dupliquer.
Time-to-market	SDK officiels (TS/Python), <i>MCP Inspector</i> , nombreux serveurs prêts à l'emploi.

1.4 Analyse comparative de l'écosystème

Maturité & communauté (chiffres, 2026).

- Gouvernance neutre (Linux Foundation / Agentic AI Foundation).
- **Registre officiel** de serveurs MCP : ~**9 600** serveurs, ~29 000 versions.
- ~**15 900** dépôts GitHub avec le topic `mcp-server` ; dépôt de référence `modelcontextprotocol/servers` ~**86 k** étoiles.
- ~**97 M** de téléchargements/mois des SDK (Python + TypeScript).
- **Adoption transverse** : Anthropic, **OpenAI**, Google, Microsoft, AWS, Cloudflare, GitHub... ~**41** % des organisations interrogées déclarent un usage en production (rapport Stacklok 2026).

Lecture critique : MCP n'est plus une curiosité de 2024 mais un standard **multi-éditeurs** en adoption rapide, ce qui réduit le risque de pari technologique. Sa jeunesse (spec qui évolue vite) reste à surveiller.

Comparaison des approches d'outillage d'un LLM.

Approche	Avantages	Inconvénients
Function calling « maison » (format propre à chaque API)	Démarrage immédiat, zéro dépendance	Couplé au fournisseur, non réutilisable , à re-maintenir à chaque LLM
Framework d'orchestration (LangChain, LlamaIndex)	Riche, nombreux connecteurs	Abstractions lourdes, lock-in framework , montée en version coûteuse
MCP (notre choix)	Standard ouvert , réutilisable, découplé du modèle , outillage (Inspector, registre)	Jeune (spec mouvante), sécurité à durcir (cf. menaces)

1.5 Matrice SWOT

Forces	Faiblesses
Standard ouvert, gouvernance neutre	Spécification jeune, encore en évolution rapide
Découplage modèle/données (pas de lock-in)	Outillage de debug/observabilité encore vert
Réutilisable par plusieurs clients	Courbe d'apprentissage côté développeurs
SDK officiels + Inspector + large écosystème	Qualité du <i>tool calling</i> variable selon les modèles (surtout locaux)

Opportunités	Menaces
Écosystème de serveurs réutilisables (registre)	Sécurité : injection de prompt, <i>tool poisoning</i>
Vers des agents multi-outils plus autonomes	<i>Confused deputy</i> / gestion des jetons OAuth
Standard adopté par les principaux éditeurs	Agents sur-privilegiés → surface d'attaque élargie
Mutualisation entre équipes internes	Dépendance à la trajectoire de la spec (versions)

Mitigations retenues pour le POC : outils en lecture seule par défaut (annotation `readOnlyHint`), unique action d'écriture restreinte (retour possible uniquement sur commande livrée) avec mention *human-in-the-loop*, *system prompt* anti-invention, schémas d'entrée plats et validés (Zod), journaux sur `stderr`.

1.6 Décision

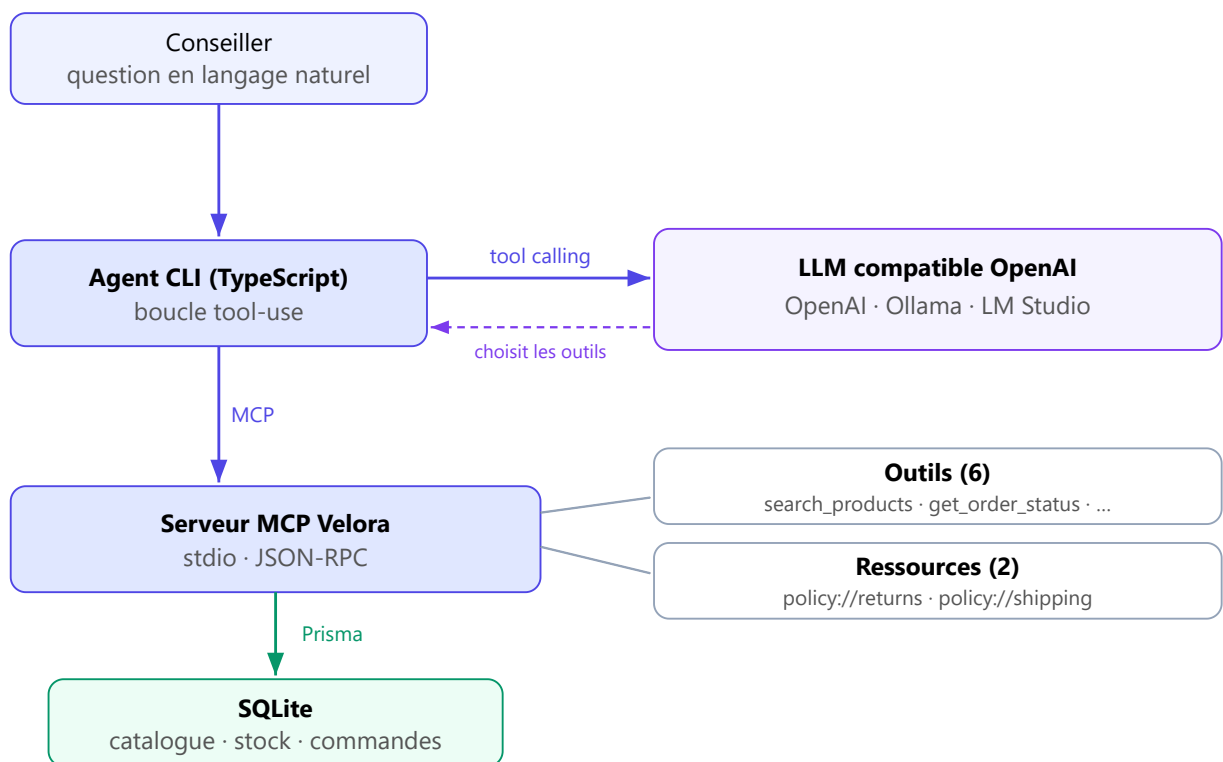
Le POC (bloc 2) démontre la **viabilité technique** et la **valeur** de MCP pour le copilote conseiller de Velora. **Recommandation : adoption**, sous conditions de durcissement sécurité (revue des actions d'écriture, *allow-list* de serveurs, journalisation) et de choix de modèle (cf. budget, bloc 3).

2. Démarche R&D et preuve de concept

2.1 Objectif du POC

Démontrer, sur le cas Velora, qu'un **serveur MCP** peut exposer les données métier (catalogue, stock, commandes, politiques) et qu'un **agent IA** les exploite pour répondre à un conseiller, le tout **testable sans clé payante**.

2.2 Architecture



Deux briques **découplées** :

1. **Serveur MCP** (`src/server.ts`), indépendant de tout LLM. Il expose des outils, des ressources et un prompt, et lit les données via Prisma/SQLite.
2. **Agent** (`src/agent/`), un **hôte MCP** qui se connecte au serveur, convertit les outils MCP en *functions* OpenAI (`bridge.ts`), puis exécute une **boucle tool-use** contre un endpoint **compatible OpenAI**.

2.3 Comment MCP fonctionne (le protocole en pratique)

MCP suit une architecture **client / serveur** à trois rôles :

- **Hôte (host)** : l'application qui pilote le LLM. Ici, notre **agent CLI**.
- **Client** : le connecteur intégré à l'hôte qui parle le protocole. Il y a **un client par serveur** connecté.
- **Serveur (server)** : le programme qui expose des capacités. Ici, le **serveur Velora**, qui publie 6 outils, 2 ressources et 1 prompt.

Les messages circulent en **JSON-RPC 2.0**, sur un **transport** au choix : `stdio` (le serveur tourne en sous-processus local, notre cas) ou *Streamable HTTP* (serveur distant). Le serveur ne « connaît » jamais le modèle : il répond à des appels normalisés, quel que soit le client.

Cycle de vie d'une session (ce que fait l'agent à chaque lancement) :

1. `initialize` : poignée de main. Client et serveur échangent leur version de protocole et leurs *capabilities*.
2. `tools/list` : le client découvre les outils disponibles et leur schéma d'entrée (JSON Schema).
3. `tools/call` : le client exécute un outil avec des arguments validés et reçoit le résultat. De même, `resources/read` sert les données et `prompts/get` les gabarits.

Trace concrète d'un appel d'outil (simplifiée) :

```
// requête client -> serveur
{ "jsonrpc": "2.0", "id": 2, "method": "tools/call",
  "params": { "name": "get_order_status", "arguments": { "reference": "VEL-1003" } } }

// réponse serveur -> client
{ "jsonrpc": "2.0", "id": 2, "result": {
  "content": [ { "type": "text", "text": "{ \"status\": \"preparing\", ... }" } ] } }
```

C'est cette indépendance (un serveur, des messages normalisés) qui rend le même serveur consommable par **plusieurs clients** : notre agent, le **MCP Inspector** ou **Claude Desktop**, sans une ligne de code à changer.

2.4 Les primitives exposées par le serveur Velora

MCP définit trois primitives. Notre serveur les utilise toutes :

- **Tools (outils)** : des actions appelables par le modèle, avec un schéma d'entrée validé. Velora en expose **6** (détaillés en 2.5).
- **Resources (ressources)** : des données en lecture, adressées par URI. Velora expose `policy://returns` et `policy://shipping` (politiques au format Markdown).
- **Prompts (gabarits)** : des modèles de message réutilisables. Velora expose `conseiller_reply`, un gabarit de réponse conseiller.

2.5 Les 6 outils en détail

Chaque outil est défini dans un fichier dédié (`src/tools/`), avec un **schéma Zod** (typage + descriptions lues par le LLM) et une **annotation** de sûreté (`readOnlyHint`). Cinq outils sont en **lecture seule** ; seul `create_return_request` écrit, et uniquement sous condition.

Outil	Entrée	Sortie	Type	Cas testé (cf. bloc « Preuves d'exécution »)
<code>search_products</code>	<code>query?</code> , <code>category?</code> , <code>color?</code> , <code>maxPriceEur?</code> , <code>inStockOnly?</code>	Liste de produits (SKU, prix, disponibilité, stock total)	Lecture	Robes en stock, 2 résultats
<code>get_product</code>	<code>sku</code>	Fiche complète + stock par taille	Lecture	VEL-CHAUS-001, stock par taille
<code>check_stock</code>	<code>sku</code> , <code>size?</code>	Disponibilité globale ou pour une taille	Lecture	VEL-CHAUS-001 taille 39, 3 en stock
<code>get_order_status</code>	<code>reference?</code> ou <code>email?</code>	Statut, articles et total d'une commande, ou liste des commandes d'un client	Lecture	VEL-1003 « En préparation » ; commandes d'Alice Martin
<code>get_return_policy</code>	<code>category?</code>	Politique de retours (Markdown)	Lecture	Renvoie la politique
<code>create_return_request</code>	<code>reference</code> , <code>sku</code> , <code>reason</code> , <code>size?</code>	RMA créé, ou erreur si la commande n'est pas livrée	Écriture	Refus sur VEL-1003 (non livrée), accepté sur VEL-1001 (livrée)

Garde-fou métier : `create_return_request` vérifie que la commande est au statut `delivered` avant d'écrire. Toute autre situation renvoie une erreur explicite, sans rien modifier. C'est la traduction concrète du principe *human-in-the-loop* (cf. 2.12).

Concrètement, un outil tient en un schéma Zod (validé et décrit pour le LLM), une annotation de sûreté et un handler. Exemple (extrait de `src/tools/checkStock.ts`) :

```
server.registerTool(
  "check_stock",
  {
    title: "Vérifier le stock",
    description: "Vérifie la disponibilité d'un produit, globalement ou pour une taille.",
    inputSchema: {
      sku: z.string().describe("SKU exact du produit, ex: VEL-CHAUS-001"),
      size: z.string().optional().describe("Taille précise, ex: 39, M, TU"),
    },
    annotations: { readOnlyHint: true, openWorldHint: false }, // outil en lecture seule
  },
  async ({ sku, size }) => {
    const p = await findProductBySku(sku);
    if (!p) return errorResult(`Aucun produit trouvé pour le SKU "${sku}"`);
    // ... renvoie le stock (global, ou pour la taille demandée)
  },
);
```

2.6 Du serveur MCP à l'agent : le pont et la boucle tool-use

L'agent ne réimplémente pas les outils : il les **réutilise** via MCP. Le passage du protocole MCP au format attendu par un LLM compatible OpenAI tient en deux fonctions (`src/agent/bridge.ts`) :

1. **Conversion des outils** : la liste `tools/list` (MCP) est transformée en *functions* OpenAI. Le schéma d'entrée MCP (JSON Schema) devient directement le champ `parameters`. Aucune redéfinition manuelle.
2. **Normalisation des résultats** : le contenu renvoyé par un outil MCP est aplati en texte pour être réinjecté au modèle.

La **boucle** (`src/agent/agent.ts`) enchaîne alors :

1. On envoie au LLM la question du conseiller et la liste des outils.
2. Si le LLM demande un (ou plusieurs) appels d'outils, l'agent les exécute **réellement** via le client MCP et lui renvoie les résultats.
3. On répète jusqu'à une réponse finale (plafond `AGENT_MAX_STEPS`, défaut 6).

Un *system prompt* **anti-invention** impose au modèle de s'appuyer sur les outils pour toute donnée factuelle (prix, stock, statut) et de ne jamais inventer.

Le cœur de la boucle (extrait de `src/agent/agent.ts`) :

```

for (let i = 0; i < maxSteps; i++) {
  const res = await llm.chat.completions.create({ model, messages, tools, tool_choice: "auto" });
  const msg = res.choices[0].message;
  messages.push(msg);

  // Aucun outil demandé : le modèle a sa réponse finale
  if (!msg.tool_calls?.length) return { answer: msg.content ?? "", steps };

  // Sinon, on exécute chaque outil via le client MCP, puis on renvoie le résultat au modèle
  for (const call of msg.tool_calls) {
    const result = await client.callTool({
      name: call.function.name,
      arguments: JSON.parse(call.function.arguments),
    });
    messages.push({ role: "tool", tool_call_id: call.id, content: mcpResultToText(result) });
  }
}

```

2.7 Choix techniques

Élément	Choix	Justification
Langage	TypeScript (Node 20+)	Cohérent avec la stack full-stack JS de Velora
Serveur MCP	<code>@modelcontextprotocol/sdk</code> (<code>McpServer</code>)	SDK officiel, API haut niveau, transport stdio
Validation	Zod	Schémas d'entrée typés + descriptions exposées au LLM
Données	Prisma 7 + SQLite (adapter better-sqlite3)	Réaliste, zéro serveur à installer, <i>seed</i> reproductible
Agent	SDK <code>openai</code> avec <code>baseUrl</code> configurable	Compatible OpenAI, Ollama, LM Studio... via <code>.env</code>
Tests	Vitest	Intégration outils (sans LLM) + boucle agent (LLM simulé)

2.8 Portabilité et test sans clé payante (note importante)

L'agent utilise l'**API compatible OpenAI**. Il fonctionne donc avec : **OpenAI** (clé payante), **un modèle local** (Ollama / LM Studio, donc **gratuit et sans clé**), ou tout fournisseur compatible (Groq, Together, OpenRouter...). On change de fournisseur en modifiant **uniquement** `LLM_BASE_URL` , `LLM_API_KEY` , `LLM_MODEL` dans `.env` .

Le **serveur MCP est indépendant du LLM** : il se teste **seul**, sans aucune clé, via `npm test` ou le *MCP Inspector*. Il est aussi consommable par **Claude Desktop** (configuration fournie), illustration concrète du « un serveur, plusieurs clients ».

Cette note figure aussi dans le `README.md` et le fichier `.env.example` .

2.9 Dépôt et installation

Dépôt : <https://github.com/Onitsag/velora-mcp-copilote> . Guide complet d'installation **sans friction** dans le `README.md` . En résumé :

```
npm install
cp .env.example .env      # profil local Ollama par défaut
npm run db:setup          # crée la base SQLite + données fictives
npm run build
npm test                  # 12 tests, sans clé API
```

2.10 Cas d'usage testés en conditions réelles

Le fichier `../demo/outils-demo.md` (généré par `npm run showcase`) contient des **appels réels** et leurs **résultats bruts**, dont des cas limites probants :

- recherche filtrée (robes en stock), fiche produit avec **stock par taille** ;
- statut d'une commande connue (`VEL-1003` , « En préparation », articles + total) ;
- **garde-fou** : `create_return_request` **refuse** une commande non livrée (`VEL-1003`) et **accepte** une commande livrée (`VEL-1001`).

Côté agent, `npm run demo` (avec un LLM configuré) produit des transcriptions dans `docs/demo/transcripts/` . La **boucle tool-use** est par ailleurs validée **sans clé** par `tests/agent.test.ts` (LLM déterministe simulé) : l'agent appelle réellement `get_order_status` puis fonde sa réponse sur le résultat.

2.11 Tests et qualité

`npm test` exécute **12 tests** (3 fichiers) :

- `tests/tools.test.ts` , intégration des 6 outils via un **vrai client MCP** (sous-processus serveur), incluant les cas d'erreur et le garde-fou de retour ;
- `tests/bridge.test.ts` , normalisation des résultats MCP vers texte ;
- `tests/agent.test.ts` , boucle tool-use de l'agent avec LLM simulé.

`pretest` régénère la base et compile, garantissant des tests **déterministes**.

2.12 Sécurité (mesures du POC)

- Outils **en lecture seule** par défaut (`readOnlyHint`) ; seule écriture : `create_return_request` , **restreinte aux commandes livrées**, avec mention explicite *human-in-the-loop*.
- *System prompt* **anti-invention** (le modèle doit s'appuyer sur les outils).
- **Schémas d'entrée plats et validés** (Zod), donc compatibilité large et moindre surface d'attaque.
- Logs serveur sur **stderr** uniquement (stdout réservé au protocole).

2.13 Limites assumées du POC

Données **fictives** ; recherche **lexicale simple** (pas de recherche vectorielle) ; pas d'authentification ni de multi-tenant ; transport **stdio** local (pas d'exposition HTTP distante). Ces points sont des pistes d'industrialisation, hors périmètre d'un POC.

3. Étude budgétaire et d'adoption

Tarifs éditeurs exprimés en USD ; parité ~1:1 € retenue pour simplifier la lecture. Volumes = hypothèses de travail pour Velora (~15 conseillers).

3.1 Hypothèse de volume

Paramètre	Hypothèse
Conseillers	15
Requêtes copilote / conseiller / jour	~30
Jours ouverts / mois	~21
Total requêtes / mois	~10 000
Tokens / requête (avec aller-retours d'outils)	~3 000 entrée + ~500 sortie
Volume mensuel	~30 M tokens entrée + ~5 M sortie

3.2 Coûts directs

a) Inférence LLM (cœur du coût variable)

Option	Prix (entrée / sortie, /M)	Coût mensuel estimé*
OpenAI gpt-4o-mini	0,15 / 0,60	~7,5 €
Claude Haiku 4.5	1,00 / 5,00	~55 €
OpenAI gpt-4o	2,50 / 10,00	~125 €
Modèle local (Ollama/LM Studio)	0 / token	0 € (coût = matériel/ops)

* 30 M × prix entrée + 5 M × prix sortie.

Leviers d'optimisation : *prompt caching* (-90 % sur l'entrée mise en cache : le *system prompt* et les définitions d'outils sont réutilisés à chaque requête) et *Batch API* (-50 %) pour les traitements asynchrones. Avec *caching*, le coût gpt-4o-mini devient **négligeable** (quelques euros/mois).

b) Hébergement & licences

- **Serveur MCP** : petit conteneur (1 vCPU / 1 Go) ≈ **5 à 15 €/mois**, ou mutualisé avec l'infra existante ≈ négligeable.

- **Base de données** : Velora dispose déjà de sa base produit/commandes.
- **Licence MCP : 0 €** (standard open source).
- **Option auto-hébergée** : machine avec GPU 16 Go (~1 500 à 2 500 € *one-shot*) pour servir un modèle 8B, ou serveur d'inférence mutualisé.

3.3 Coûts indirects

Poste	Estimation
Industrialisation POC → prod (auth, connecteurs réels, transport HTTP, observabilité, revue sécu, intégration UI)	~15 à 25 j/h
Formation des conseillers (outil conversationnel simple)	~0,5 j × 15 ≈ 7,5 j/h
Montée en compétence MCP des développeurs	~2 à 3 j/h
Maintenance courante	~1 à 2 j/mois

3.4 Analyse d'impact

- **Courbe d'apprentissage** : **faible** côté conseillers (c'est un chat) ; **modérée** côté développeurs (MCP récent, mais SDK + Inspector matures).
- **Productivité** : gain attendu sur le **temps de recherche d'information** (objectif -30 à -50 % sur ces tâches), **onboarding raccourci** des nouveaux conseillers (le copilote sert de mémoire opérationnelle).
- **Risque transitoire** : fiabilité (hallucinations) au démarrage → atténué par les garde-fous (anti-invention, lecture seule par défaut, supervision initiale).

3.5 Synthèse ROI

À ces volumes, le **coût d'inférence cloud est marginal** (≈ 7,5 €/mois en gpt-4o-mini, voire ~0 € en local) face au **temps conseiller économisé** (le coût dominant est salarial). L'investissement réel est l'**industrialisation** (~15 à 25 j/h) et la **conduite du changement**. Le découplage MCP permet en outre de **commencer en local (0 €, données sur site)** puis de basculer vers une API managée si besoin, **sans réécrire** le serveur. Décision : **adoption recommandée**, démarrage en local pour la confidentialité et le coût.

4. Ingénierie pédagogique

L'objectif du Learning Lab est aussi de **transmettre** la compétence à mon équipe. En tant que *lead developer*, mon rôle n'est pas de faire une simple démo, mais de rendre mes collègues **autonomes** sur MCP. Cette section décrit donc le dispositif de transfert : un **atelier pratique** pour des pairs développeurs (matériel complet dans `../atelier/`), puis un **plan de déploiement progressif** vers l'équipe (4.4).

4.1 Objectifs pédagogiques

À l'issue de l'atelier (≈ 1 h 30), un participant sait :

1. **Expliquer** ce qu'est MCP et ses 3 primitives (tools, resources, prompts) ;
2. **Lire** un serveur MCP existant et le tester avec le *MCP Inspector* ;
3. **Écrire un nouvel outil** (schéma Zod + handler) et le faire apparaître ;
4. **Comprendre le pont** MCP → agent compatible OpenAI (réutilisation des outils) ;
5. **Tester** son outil (Vitest) sans dépendre d'un LLM.

4.2 Scénario / déroulé chronologique

Durée	Phase	Contenu
20 min	Théorie	Pourquoi MCP ? Le problème Velora ; primitives ; « un serveur, plusieurs clients » ; sécurité (injection, <i>tool poisoning</i>).
15 min	Démonstration	Lancer le serveur + Inspector ; appeler <code>search_products</code> , <code>get_order_status</code> ; lancer l'agent (modèle local) sur une question réelle.
45 min	Coding Kata	Chaque participant ajoute l'outil <code>get_shipping_estimate</code> (cf. <code>atelier/kata.md</code>), le teste à l'Inspector puis via le test fourni.
10 min	Débrief & futur	Revue des solutions ; limites & pistes (HTTP distant, RAG, sécurité) ; projection : agents multi-serveurs.

Détail complet et minutage : `../atelier/scenario.md` .

4.3 Support d'exercice pratique (Coding Kata)

Énoncé : « Ajouter au serveur l'outil `get_shipping_estimate({ country, weightKg })` qui renvoie le délai et le tarif estimés selon la politique de livraison. » Le kata fournit un **squelette à compléter** et un **test rouge** qui doit passer au vert.

- Énoncé + étapes guidées + solution : `../atelier/kata.md`
- Squelette de départ : `../atelier/kata-starter/`

L'exercice est volontairement **isomorphe** aux outils existants : le participant réutilise le patron `registerXxx(server)` déjà en place, ce qui ancre la compétence « écrire un outil MCP » de façon autonome.

4.4 Plan de transfert à l'équipe (au-delà de l'atelier)

L'atelier amorce la compétence ; son ancrage durable passe par un déploiement progressif, que je piloterais ainsi :

1. **Pilote** (semaines 1 et 2) : 2 à 3 conseillers volontaires utilisent le copilote en conditions réelles, avec un développeur référent MCP pour le support et la collecte des retours.
2. **Documentation interne** : ce rapport et le `README` servent de socle ; on y ajoute les cas d'usage Velora réellement rencontrés (FAQ, exemples).
3. **Industrialisation** (cf. budget, bloc 3) : connecteurs vers le vrai back-office, transport HTTP, authentification, observabilité, revue sécurité.
4. **Généralisation** : ouverture à l'ensemble des conseillers, avec mesure des gains (temps de réponse, durée d'onboarding des nouvelles recrues).
5. **Capitalisation** : chaque équipe peut publier ses propres serveurs MCP, réutilisables par les autres (logique « un serveur, plusieurs clients »).

5. Posture de Lead Developer (démarche & synthèse)

5.1 Démarche de veille

La veille a combiné sources **primaires** (spécification MCP, documentation des SDK officiels, pages de tarification éditeurs) et **secondaires** (registre officiel, retours d'adoption, littérature sécurité). Les chiffres et faits techniques du rapport ont été **vérifiés à la source** (juin 2026) plutôt que repris de mémoire, la technologie évoluant vite.

5.2 Esprit critique

MCP a été évalué **sans complaisance** : au-delà de la « hype », le rapport identifie des **faiblesses** (spec jeune, *tool calling* inégal selon les modèles) et des **menaces** réelles (injection de prompt, *tool poisoning*, sur-privileges). Le choix d'architecture **découplée** (serveur indépendant du LLM) est lui-même une réponse critique au risque de *lock-in*.

5.3 Décisions d'ingénierie notables

- **Agent compatible OpenAI** plutôt que lié à un seul fournisseur → le projet est **testable gratuitement** (modèle local) et **portable** (cloud ou local via `.env`). Décision motivée par la contrainte « le correcteur doit pouvoir tester sans clé payante ».
- **Prisma 7 + adapter** : prise en compte des évolutions récentes (driver adapters, `prisma.config.ts`) constatées **pendant** le build, et adaptation en conséquence.
- **Testabilité** : l'agent accepte un LLM **injecté**, ce qui permet de valider la boucle *tool-use* **sans clé** (test déterministe).

5.4 Vulgarisation

Le rapport s'adresse à une **direction technique** : analogies (« USB-C de l'IA »), tableaux de synthèse, SWOT, exemple budgétaire chiffré, et un POC **exécutable** documenté pas à pas. L'objectif est qu'un décideur comme un développeur puissent se forger une opinion **et** reproduire la démonstration.

5.5 Bilan

Le Learning Lab a permis de passer de la **veille** (comprendre MCP et son écosystème) à la **preuve** (un POC fonctionnel, testé, documenté) puis au **transfert** (un atelier et un kata prêts à l'emploi). La recommandation d'adoption est **étayée** par des faits, un code opérationnel et une analyse économique, tout en restant lucide sur les conditions de mise en production.

Annexe A : Installation et utilisation

Prérequis

- Node.js 20 ou plus récent, et npm.
- Optionnel (pour la démo agent gratuite) : Ollama avec un modèle gérant le tool-calling, par exemple `llama3.1`.

Installation

```
git clone https://github.com/Onitsag/velora-mcp-copilote.git
cd velora-mcp-copilote
npm install
cp .env.example .env          # profil Ollama local par défaut
npm run db:setup              # base SQLite + données fictives Velora
npm run build
```

Vérifier sans aucune clé

```
npm test                      # 12 tests (outils MCP + boucle agent simulée)
npm run showcase              # appels réels des outils -> docs/demo/outils-demo.md
npm run inspect               # MCP Inspector sur http://localhost:6274
```

Lancer l'agent (copilote)

```
# Option A, modèle local gratuit :
ollama pull llama3.1
npm run agent -- "Où en est la commande VEL-1003 ?"

# Option B, OpenAI : renseigner le profil OpenAI dans .env, puis :
npm run agent -- "Avez-vous la robe Lila en taille S ?"
```

Le serveur MCP ne dépend d'aucun LLM : il se teste seul (`npm test` , Inspector) et se branche aussi sur Claude Desktop (un serveur, plusieurs clients).

Annexe B : Preuves d'exécution (appels réels du serveur MCP)

Ce document est généré par `npm run showcase` : il contient des **appels réels** du client MCP vers le serveur Velora et les **résultats bruts** renvoyés.

Outils disponibles

- `search_products` : Recherche dans le catalogue Velora par mots-clés, catégorie, couleur et prix maximum. Renvoie pour chaque produit son SKU, son prix et sa disponibilité.
- `get_product` : Renvoie la fiche complète d'un produit (description, prix, stock par taille) à partir de son SKU.
- `check_stock` : Vérifie la disponibilité d'un produit, globalement ou pour une taille précise.
- `get_order_status` : Renvoie le statut d'une commande à partir de sa référence (ex: VEL-1003), ou la liste des commandes d'un client à partir de son email.
- `get_return_policy` : Renvoie la politique de retours et d'échanges de Velora (délais, conditions, remboursement).
- `create_return_request` : Enregistre une demande de retour pour un article d'une commande LIVRÉE. Action d'écriture : en production, elle doit être confirmée par un humain (human-in-the-loop).

Ressources disponibles

- `policy://returns` : politique-retours
- `policy://shipping` : politique-livraison

Rechercher les robes en stock

Appel : `search_products({"category":"Robes","inStockOnly":true})`

```
{
  "count": 2,
  "products": [
    {
      "sku": "VEL-ROBE-001",
      "name": "Robe portefeuille Lila",
      "category": "Robes",
      "color": "Violet",
      "price": "79,00 €",
      "available": true,
      "totalStock": 10
    },
    {
      "sku": "VEL-ROBE-002",
      "name": "Robe chemise Origan",
      "category": "Robes",
      "color": "Kaki",
      "price": "65,00 €",
      "available": true,
      "totalStock": 6
    }
  ]
}
```

Fiche produit : bottines Chelsea

Appel : `get_product({"sku": "VEL-CHAUS-001"})`

```
{
  "sku": "VEL-CHAUS-001",
  "name": "Bottines Chelsea Ardoise",
  "description": "Bottines en cuir, élastiques latéraux.",
  "category": "Chaussures",
  "color": "Noir",
  "price": "119,00 €",
  "available": true,
  "variants": [
    {
      "size": "38",
      "stockQty": 2,
      "available": true
    },
    {
      "size": "39",
      "stockQty": 3,
      "available": true
    },
    {
      "size": "40",
      "stockQty": 0,
      "available": false
    },
    {
      "size": "41",
      "stockQty": 1,
      "available": true
    },
    {
      "size": "42",
      "stockQty": 2,
      "available": true
    }
  ]
}
```

Vérifier le stock de la taille 39

Appel : `check_stock({"sku": "VEL-CHAUS-001", "size": "39"})`

```
{
  "sku": "VEL-CHAUS-001",
  "size": "39",
  "stockQty": 3,
  "available": true
}
```

Statut de la commande VEL-1003

Appel : `get_order_status({"reference": "VEL-1003"})`

```
{
  "reference": "VEL-1003",
  "status": "preparing",
  "statusLabel": "En préparation",
  "carrier": null,
  "trackingNumber": null,
  "createdAt": "2026-06-28T21:25:21.920Z",
  "customer": {
    "name": "Chloé Nguyen",
    "email": "chloe.nguyen@example.com"
  },
  "items": [
    {
      "sku": "VEL-CHAUS-001",
      "size": "39",
      "qty": 1,
      "unitPrice": "119,00 €"
    },
    {
      "sku": "VEL-PULL-001",
      "size": "M",
      "qty": 1,
      "unitPrice": "69,00 €"
    }
  ],
  "total": "188,00 €"
}
```

Commandes du client alice.martin

Appel : `get_order_status({"email": "alice.martin@example.com"})`

```
{
  "customer": "Alice Martin",
  "email": "alice.martin@example.com",
  "orders": [
    {
      "reference": "VEL-1001",
      "status": "delivered",
      "statusLabel": "Livrée",
      "createdAt": "2026-06-28T21:25:21.883Z",
      "itemsCount": 2
    },
    {
      "reference": "VEL-1005",
      "status": "returned",
      "statusLabel": "Retournée",
      "createdAt": "2026-06-28T21:25:21.957Z",
      "itemsCount": 1
    }
  ]
}
```

Retour refusé (commande non livrée) ⚠️ (isError)

Appel : `create_return_request({"reference":"VEL-1003","sku":"VEL-PULL-001","reason":"Trop grand"})`

```
{"error":"Un retour n'est possible que pour une commande livrée. Statut actuel de VEL-1003 : preparing."}
```

Retour accepté (commande livrée VEL-1001)

Appel : `create_return_request({"reference":"VEL-1001","sku":"VEL-ROBE-001","reason":"Taille trop grande"})`

```
{
  "message": "Demande de retour enregistrée (RMA créé).",
  "rmaId": 15,
  "reference": "VEL-1001",
  "sku": "VEL-ROBE-001",
  "size": "M",
  "status": "requested",
  "note": "En production, cette action nécessite une confirmation humaine avant validation."
}
```


Annexe C : Ressources

- Dépôt du POC (code complet) : <https://github.com/Onitsag/velora-mcp-copilote>
- Spécification et documentation MCP : <https://modelcontextprotocol.io>
- SDK TypeScript MCP : <https://github.com/modelcontextprotocol/typescript-sdk>
- Dépôt de référence des serveurs MCP : <https://github.com/modelcontextprotocol/servers>
- Registre officiel de serveurs MCP : <https://registry.modelcontextprotocol.io>